Younes Arjdal
21203492
Master 1 MIND

BirdCLEF+ 2026 : Classification audio multi-label de la faune du Pantanal

Une approche par descripteurs spectraux et apprentissage classique



1. Introduction et Analyse des données

1.1 Présentation du problème et des sources de données

Avant de construire les modèles, je commence par analyser les données afin d'identifier les contraintes du problème et de guider les choix de feature engineering, de validation et d'entraînement. Le challenge BirdCLEF+ 2026 demande d'identifier les espèces animales présentes dans des enregistrements audio passifs du Pantanal (Brésil). À partir d'un segment de cinq secondes, on doit prédire la probabilité de présence de chacune des 234 espèces cibles, réparties entre oiseaux, amphibiens, insectes, mammifères et reptiles. La métrique d'évaluation est la moyenne des AUC-ROC calculées sur chaque classe, ce qui signifie que toutes les espèces comptent autant les unes que les autres, peu importe leur fréquence.

Les données fournies sont organisées en trois ensembles distincts présentés dans le tableau 1.1.

	Base 1 : train_audio	Base 2 : train_soundscapes	Test
Forme	1 audio entier (durée variable)	1 segment de 5s	1 segment de 5s
Source	xeno-canto + iNaturalist	Recordings passifs Pantanal	Recordings passifs Pantanal
Type de label	Mono-label (1 espèce principale)	Multi-label (vecteur binaire)	Multi-label (probabilités)
Nombre d'exemples	35549	1478 segments	≈ 7200 segments
Nombre de classes représentées	206/234	75/234	234 en théorie

Tableau 1.1 Les trois ensembles de données.

Le format audio est identique partout : OGG Vorbis, mono, 32 kHz. La difficulté ne vient donc pas du format, mais des différences entre la façon dont les données d'entraînement ont été collectées et la façon dont le test sera évalué.

1.2 Distribution des classes et couverture des cibles

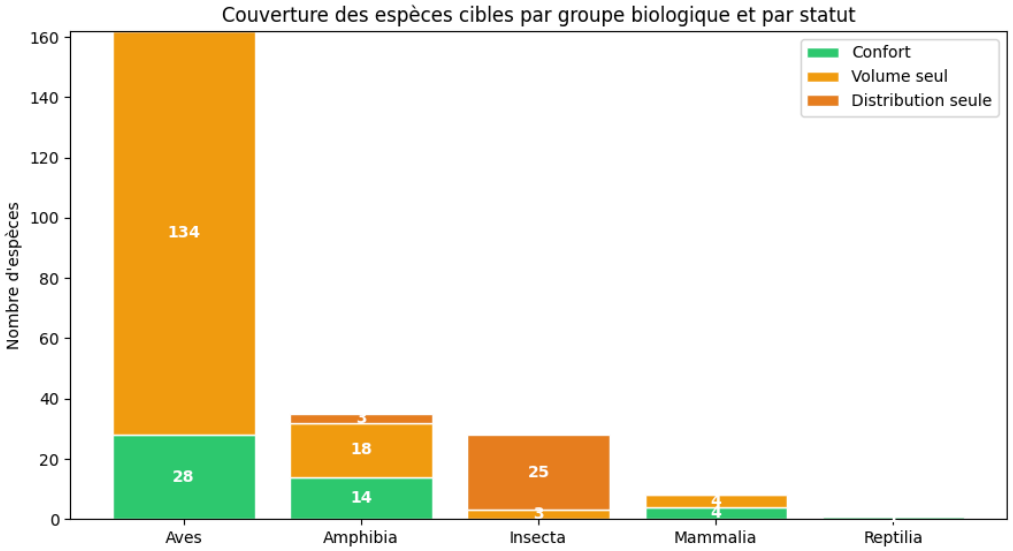
La répartition des espèces entre les groupes biologiques est très déséquilibrée : les oiseaux dominent largement avec 162 espèces sur 234 (69 %), suivis des amphibiens (35), des insectes (28), des mammifères (8) et d'un seul reptile. Au sein de la Base 1, le nombre d'audios par espèce varie de 1 à 499, avec une médiane à 125. Quatre espèces ne disposent que d'un seul enregistrement, ce qui rendra leur apprentissage impossible. Du côté de la Base 2, chaque segment contient en moyenne 4,2 espèces simultanées, avec

jusqu'à 10 espèces en même temps : la nature multi-label des soundscapes est donc bien réelle, et non un cas marginal.

En croisant les espèces présentes dans chaque base, on obtient quatre statuts pour les 234 cibles :

- **47 espèces "Confort"** : présentes dans les deux bases. Situation favorable.
- **159 espèces "Volume seul"** : uniquement dans la Base 1. Beaucoup de données, mais jamais vues en conditions de soundscape.
- **28 espèces "Distribution seule"** : uniquement dans la Base 2. Peu d'exemples, mais distribution proche du test.
- **0 espèce aveugle** : toutes les cibles ont au moins une source de données.

La figure 1 ci-dessous montre comment ces statuts se répartissent par groupe biologique.



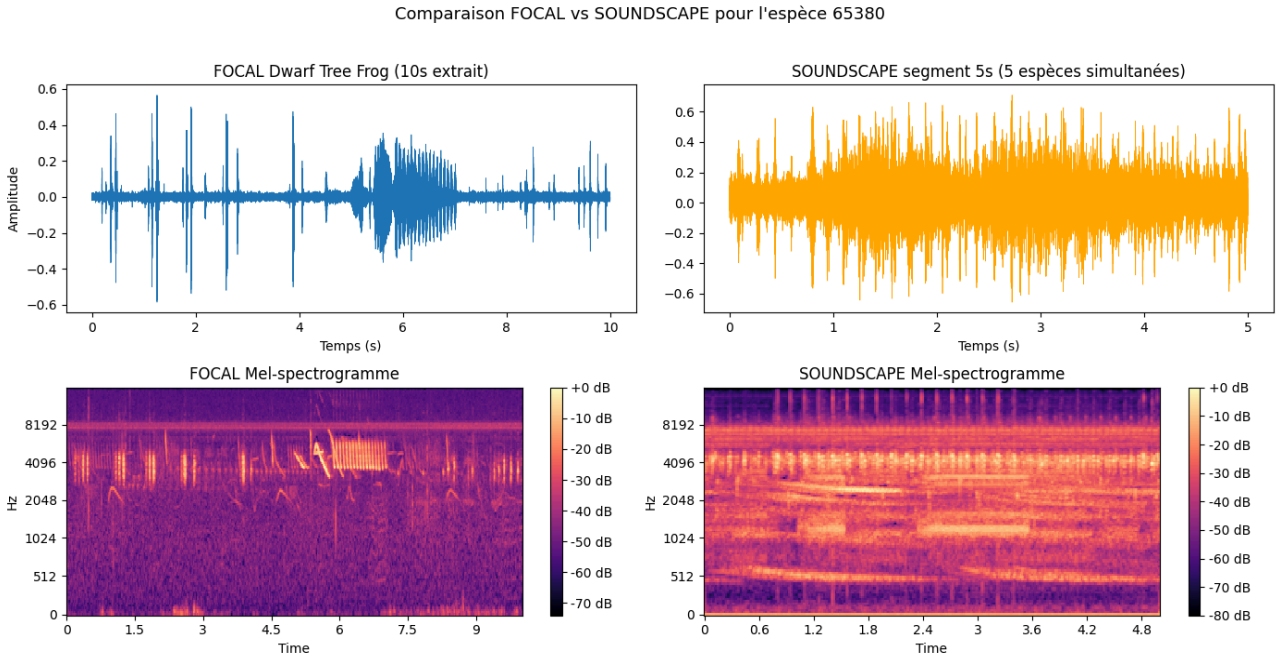
On voit immédiatement deux choses. D'abord, la majorité des oiseaux (134 sur 162) tombent en "Volume seul" : on aura beaucoup d'exemples mais jamais en conditions réelles. Ensuite, presque tous les insectes (25 sur 28) sont en "Distribution seule" : pour les apprendre, on ne pourra compter que sur les 1 478 segments de la Base 2.

1.3 Trois décalages entre entraînement et test

L'écart entre les données d'entraînement et la situation du test peut se résumer en trois décalages.

Décalage n°1 Recording focal contre enregistrement passif

La Base 1 contient des recordings ciblés : un opérateur dirige son micro vers une espèce identifiée, à courte distance. Les soundscapes, eux, sont enregistrés par des capteurs autonomes qui captent tout ce qui passe à portée. La figure 2 compare un même *Dwarf Tree Frog* dans les deux contextes.



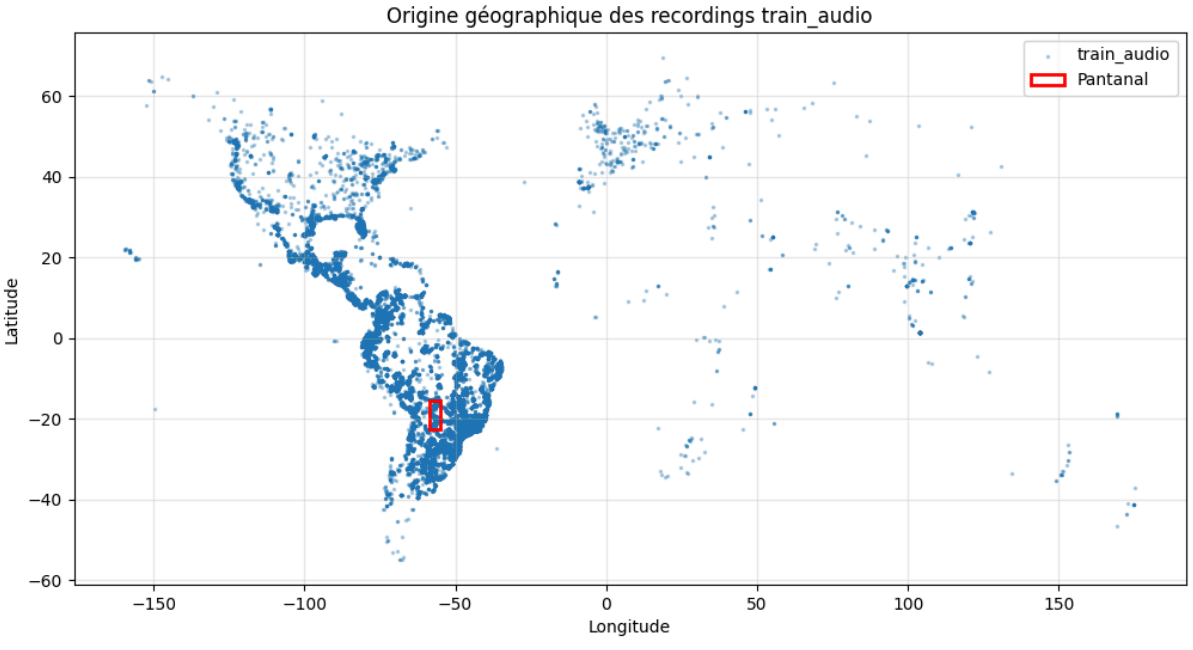
Sur le focal, on distingue clairement chaque croassement, séparé par des silences. Sur le soundscape, la même grenouille est noyée parmi quatre autres espèces et un bruit de fond continu. C'est le décalage principal du problème : un modèle entraîné sur le focal apprend à reconnaître un signal isolé, alors qu'on lui demandera de reconnaître ce signal dans un mélange.

Décalage n°2 Deux sources documentaires différentes

La Base 1 combine xeno-canto (23 043 fichiers) et iNaturalist (12 506 fichiers). Xeno-canto fournit un rating de qualité entre 1 et 5 (la majorité des fichiers sont à 4 ou plus). iNaturalist ne fournit aucun rating et tous les fichiers iNat sont à 0. On ne peut donc pas filtrer par qualité de la même manière sur les deux collections. Par ailleurs, 12 % des fichiers (uniquement XC) disposent de secondary_labels, ce qui pourra servir à enrichir l'étiquetage.

Décalage n°3 Couverture géographique mondiale, test au Pantanal

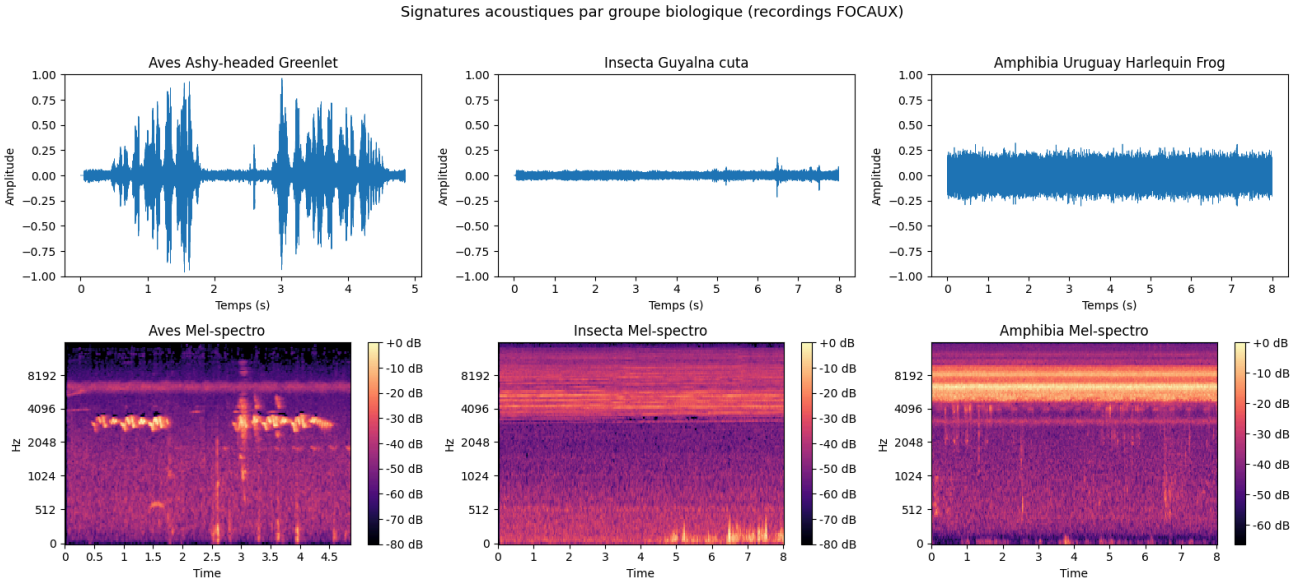
Le test se déroule uniquement au Pantanal, mais les recordings de la Base 1 viennent du monde entier. La figure 3 cartographie l'origine des fichiers.



réalisé au Pantanal. Or, plusieurs espèces peuvent présenter des variations (des genres de dialecte) selon la région : un même oiseau peut chanter différemment en Amazonie et au Pantanal. Pour ces 70 espèces, le modèle apprend donc potentiellement sur des chants qu'il ne retrouvera pas tels quels au test.

1.4 Propriétés acoustiques des signaux

L'écoute et la visualisation de recordings issus de différents groupes biologiques montrent que les signaux à reconnaître n'ont rien à voir entre eux. La figure 4 illustre cela sur un oiseau, un insecte et un amphibien.



Les **oiseaux** produisent des syllabes courtes et modulées séparées par des silences. Les **insectes** émettent un signal continu à large bande sans structure temporelle particulière. Les **amphibiens** produisent un signal également continu, mais concentré sur une bande de fréquence étroite. Ces trois types de signaux demanderont des descripteurs différents : les statistiques globales (moyennes, écarts-types) suffisent pour les insectes et amphibiens, mais aplatissent la dynamique nécessaire à la reconnaissance des oiseaux. Le jeu de features devra donc combiner information statique et dynamique.

Deux autres points sont à noter. D'abord, l'essentiel de l'énergie est concentré sous 8 kHz, alors que le taux d'échantillonnage de 32 kHz permettrait d'aller jusqu'à 16 kHz : un sous-échantillonnage à 16 kHz est envisageable sans perte d'information. Ensuite, les fichiers de la Base 1 ont des durées très hétérogènes (de 0,03 s à 549 s, médiane à 19,6 s), alors que le test attend des segments de 5 s exactement. La stratégie de découpage est donc à définir avec soin.

1.5 Synthèse des constats

#	Problème	Conséquence pour la suite
1	Recording focal != soundscape passif	Validation interne pas représentative du test
2	Deux sources de qualité hétérogène	Filtrage qualité à concevoir avec précaution
3	Recordings mondiaux,test local	Risque de dialectes pour 70 espèces
4	28 espèces uniquement dans la base 2	Apprentissage limité (surtout les insectes)
5	Trois signatures acoustiques différentes	Features couvrant statique + dynamique

L'analyse fait apparaître cinq problèmes principaux qui guideront les choix de la section suivante. S'ajoutent deux contraintes structurelles : la tâche est multi-label (4,2 espèces simultanées en moyenne dans la Base 2) et les durées des fichiers d'entraînement sont très variables (0,03 s à 549 s pour un test fixé à 5 s).

2. Première approche : un vecteur fait main

2.1 Choix de représentation

L'analyse a établi trois constats qui orientent directement la construction du vecteur d'entrée. Les sons produits par les espèces diffèrent fortement selon le groupe biologique (transitoire chez les oiseaux, stationnaire large bande chez les insectes, stationnaire bande étroite chez les amphibiens) ; l'essentiel de l'énergie utile se concentre sous 8 kHz ; et la cible est un segment de 5 s imposé par la compétition.

Je construis donc une pipeline qui prend un segment audio de 5 s et le transforme en un vecteur de 170 dimensions, combinant quatre familles de descripteurs : MFCC + delta + delta-delta (l'idée c'est timbre et dynamique), features spectrales (centroïde, bande passante, rolloff, flatness, contrast qui capturent la forme du spectre des signaux stationnaires), features temporelles (RMS et zero-crossing rate), et chroma (tonalité). Pour chaque descripteur, je garde la moyenne et l'écart-type sur le segment.

Les audios sont sous-échantillonnés à 16 kHz (justifié par l'analyse spectrale), puis découpés en segments non-overlapping de 5 s. Pour éviter qu'un fichier de plusieurs minutes ne sur-représente son espèce, je cape à 20 segments par fichier échantillonnés uniformément. La Base 1 produit ainsi 198 437 segments d'entraînement, la Base 2 reste à ses 1 478 segments natifs.

La tâche multi-label sur 234 classes est traitée par décomposition One-vs-Rest : un classifieur binaire par espèce, sortie en probabilité. Le déséquilibre est compensé par une pondération automatique des positifs (scale_pos_weight plafonné à 100).

2.2 Comparaison de trois classifieurs

Je compare trois classifieurs binaires de natures différentes : une régression logistique (SGD, linéaire, baseline incontournable), un XGBoost (gradient boosting, non-linéaire, état de l'art tabulaire) et un CatBoost (gradient boosting GPU, robuste sur features hétérogènes). L'entraînement se fait sur l'intégralité de la Base 1, l'évaluation sur l'intégralité de la Base 2.

Classifieur	Macro AUC global	AUC sur les 47 “confort”	AUC Mammalia	AUC Aves	AUC Amphibia	Temps
SGD	0.543	0.569	0.518	0.602	0.518	5min
XGBoost	0.609	0.674	0.841	0.651	0.653	7min
CatBoost	0.652	0.742	0.839	0.752	0.680	2min

CatBoost domine sur toutes les métriques, et reste le plus rapide (grâce au GPU). Je le retiens comme baseline et **le soumets sur Kaggle : le score officiel obtenu est 0,728** sur le test caché, nettement au-dessus du score local (0,65). Concernant les hyperparamètres, j'ai retenu pour CatBoost une profondeur d'arbre modérée (depth=6) pour limiter le surapprentissage sur les classes rares, un learning rate de 0,05 avec early stopping pour converger sans bruit, et une régularisation L2 (l2_leaf_reg=3) pour stabiliser les modèles sur les classes peu représentées. Le scale_pos_weight est plafonné à 100 pour éviter qu'une classe ultra-rare ne dégénère la fonction de coût. Ces valeurs constituent un compromis robuste classique plutôt qu'un optimum tuné(un tuning bayésien dédié est discuté en section 5.3).

2.3 Observations qui orientent la suite

Quatre constats ressortent. Les classes apprenables atteignent une bonne performance : sur les 47 classes "Confort", la moyenne CatBoost monte à 0,742, et certaines espèces dépassent 0,98 (singe hurleur, perroquets, kiskadee). La pipeline est donc saine. Les 28 classes "Base 2 seule" restent à 0,5 sur les trois modèles, par construction : aucun positif en Base 1 pour les entraîner. Elles tirent mécaniquement la macro AUC vers le bas. Trois classes sont "anti-prédites" (AUC < 0,4 chez CatBoost : trsowl, 116570, magant1) malgré des centaines voire des milliers d'exemples d'entraînement : c'est le symptôme typique d'un fort domain gap focal → soundscape. Enfin, la performance varie fortement par groupe biologique (Mammalia 0,84, Aves 0,75, Amphibia 0,68, Insecta 0,50, Reptilia 0,43), ce qui confirme que des features purement statistiques ne capturent pas la même information selon la nature du signal.

Ces constats orientent directement une v2 : entraîner aussi sur la Base 2 (en gardant des fichiers soundscape séparés pour la validation, afin d’éviter que le modèle apprenne trop spécifiquement les exemples évalués.) pour récupérer les 28 classes "Distribution seule" et améliorer la robustesse au domain gap sur les 47 "Confort".

2.4 Tentative d'embeddings pré-entraînés

J'ai également testé une seconde piste, l'extraction d'embeddings via birdnet (modèle BirdNET v2.4), entraîné en grande partie sur xeno-canto et donc *a priori* bien adapté. Le modèle produit un vecteur 1024-dim par segment de 3 s. En pratique, l'inférence sur CPU s'est révélée trop lente pour être exploitable : environ 2 s par fichier focal en moyenne, soit plusieurs heures pour la Base 1, et les tentatives d'optimisation (parallélisation, batching) n'ont pas apporté les gains espérés. J'ai abandonné cette piste pour rester sur la pipeline fait main, qui donne déjà un score solide et dispose d'une marge claire d'amélioration via la v2.

3. Deuxième approche : la v2

3.1 Trois améliorations cumulées

À la lumière des observations de la v1, je conçois une seconde version qui combine trois améliorations.

La première étend le vecteur de features de 170 à 307 dimensions. J'ajoute deux statistiques d'ordre supérieur (skewness et kurtosis) aux MFCC pour mieux capter la dynamique temporelle, huit bandes mel agrégées (moyenne et écart-type) pour discriminer les signatures stationnaires des insectes et amphibiens qui posaient problème en v1, et un taux de silence pour distinguer les fichiers focaux denses des soundscapes plus aérés.

La deuxième amélioration concerne la cible d'entraînement. Au lieu d'utiliser uniquement primary_label, je passe en multi-label en incorporant les secondary_labels présents dans 12,2 % des fichiers de la Base 1. Le label devient un vecteur binaire de 234 dimensions, ce qui donne mécaniquement plus d'exemples positifs pour les espèces co-occurrentes.

La troisième et plus importante consiste à combiner Base 1 et Base 2 en entraînement. La Base 2 a la même distribution que le test, mais elle est petite (1 478 segments) et donc facile à sur-apprendre. Pour éviter ce piège, je découpe la Base 2 par fichier soundscape : 80 % (52 fichiers, 1 182 segments) rejoignent l'entraînement, 20 % (14 fichiers, 296 segments) restent de côté pour mesurer la performance honnêtement. Cette stratégie débloque les 28 classes "Base 2 seule" et permet d'entraîner 229 classes au total, contre 47 en v1.

3.2 Résultats sur les trois mêmes classifieurs

Je réutilise le même protocole : SGD, XGBoost et CatBoost en One-vs-Rest, avec early stopping sur le hold-out. L'évaluation se fait sur les 296 segments du hold-out, où 42 classes ont au moins un positif et sont donc évaluables.

Classifieur	Macro AUC	AUC Base 1 Confort	AUC Base 2 seule	Temps
SGD	0.641	0.642	0.639	8 min
XGBoost	0.749	0.816	0.639	44 min

CatBoost	0.803	0.880	0.677	14 min

CatBoost domine encore nettement, +0,05 sur XGBoost et +0,16 sur SGD, tout en restant le plus rapide grâce au GPU. **Soumis sur Kaggle, il atteint un score officiel de 0,737** sur le test caché, contre 0,728 pour la v1, soit un gain de +0,009.

3.3 Analyse du gain

Le gain Kaggle est plus modeste que ce que les chiffres locaux pouvaient laisser espérer. Trois raisons l'expliquent. D'abord, les chiffres locaux ne sont pas directement comparables entre v1 et v2 : la v1 évaluait sur la Base 2 entière (1 478 segments, 75 classes), la v2 sur un sous ensemble beaucoup plus petit (296 segments, 42 classes). Le seul juge réellement comparable reste donc le score Kaggle officiel.

Ensuite, le gain principal attendu débloquer les 28 classes "Base 2 seule" ne se traduit que partiellement. Sur la v2, leur AUC moyenne monte à 0,68 contre 0,5 forcé en v1, mais la moitié d'entre elles reste plafonnée à 0,5. Les insectes en particulier ont des signatures très stationnaires que des features statistiques peinent à discriminer entre sons proches.

Enfin, les 47 classes "Confort" gagnent fortement en performance (0,88 contre 0,74 en v1), mais elles étaient déjà parmi les mieux prédites : le gain absolu sur ces classes n'a qu'un poids limité dans la macro AUC totale du test caché, qui est tirée vers le bas par les classes difficiles.

Le bilan reste néanmoins positif : la pipeline gère désormais 229 classes au lieu de 47, intègre deux sources de données complémentaires, et conserve une marge claire d'amélioration via du tuning d'hyperparamètres, du stacking XGBoost-CatBoost ou une bascule vers des embeddings sémantiques pré-entraînés. Il est aussi possible que l'écart entre la v1 et la v2 soit plus net sur le score privé final. Le score public ne reflète qu'une partie du test caché, alors que l'analyse d'erreurs montre que la v2 apporte des gains plus profonds que le simple +0,009 observé sur Kaggle : elle débloque des classes que la v1 ne pouvait pas apprendre et améliore fortement plusieurs espèces déjà présentes dans les deux bases.

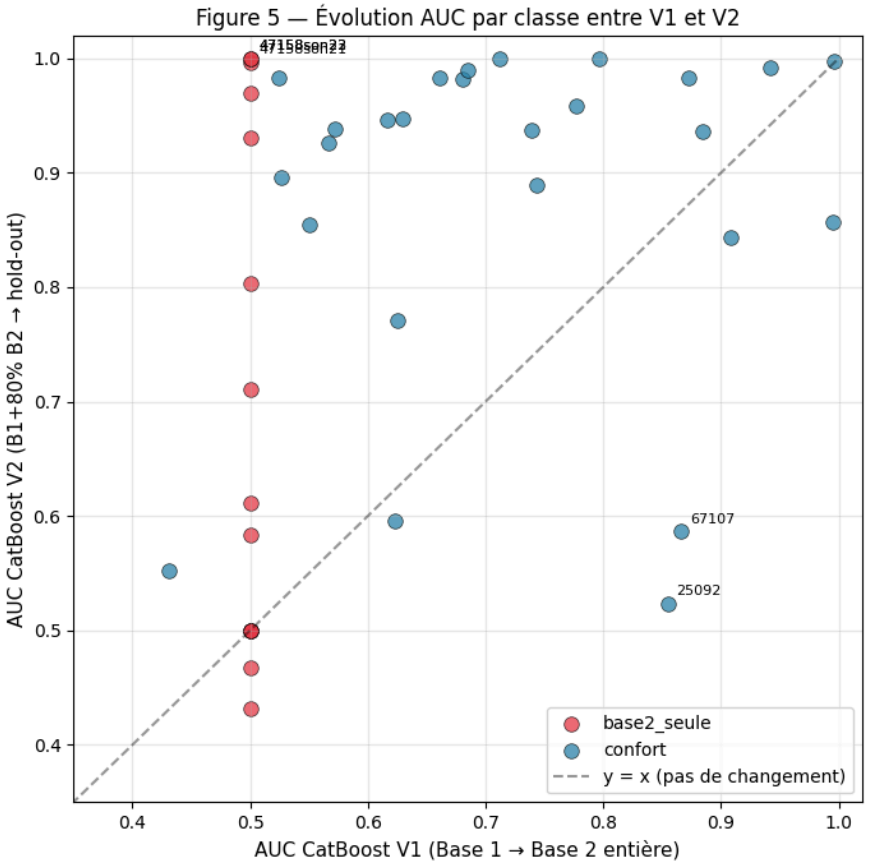
4. Analyse d'erreurs : où la pipeline progresse, où elle bloque

4.1 Cadre

Je me concentre ici sur les deux modèles soumis à Kaggle, CatBoost v1 et CatBoost v2, qui sont les seuls à avoir un score officiel sur le test caché. L'analyse porte sur les classes évaluables dans le sous ensemble 20 % de la Base 2, en particulier les 42 classes qui ont au moins un positif et qui sont donc comparables entre les deux versions.

4.2 Évolution AUC par classe entre v1 et v2

La Figure 5 reporte chaque classe comparable sur un nuage AUC v1 contre AUC v2. La ligne y = x représente l'absence de changement : au-dessus, la v2 améliore ; en dessous, elle dégrade.



Sur ces 42 classes, le delta moyen v2 − v1 est de **+0,165**. Vingt-neuf classes sont franchement améliorées (Δ > +0,02), cinq stables, et huit régressées. La progression est portée par deux dynamiques distinctes : d'un côté, le déblocage mécanique de classes qui plafonnaient à 0,5 en v1 (parce que non entraînées) ; de l'autre, le gain de généralisation sur des classes déjà apprises, grâce à l'ajout de données soundscape qui match la distribution dans l'entraînement.

L'agrégation par groupe biologique confirme que tous les groupes progressent :

Groupe	Nb classes	AUC v1	AUC v2	delta
Mammalia	3	0.785	0.991	+0.206
Aves	9	0.756	0.931	+0.175
Insecta	13	0.5	0.662	+0.162
Amphibia	16	0.668	0.825	+0.157
Reptilia	1	0.431	0.552	+0.121

Le gain sur Insecta est particulièrement parlant : quatre sons (son17, son21, son22, son23) passent de 0,5 forcé à des AUC entre 0,97 et 1,00. La v2 ne se contente pas d'améliorer marginalement la v1, elle débloque toute une catégorie de classes que la v1 ignorait par construction. Les amphibiens "Base 2 seule", comme le Guaraní leaf-litter frog (0,5 → 0,93), profitent du même mécanisme.

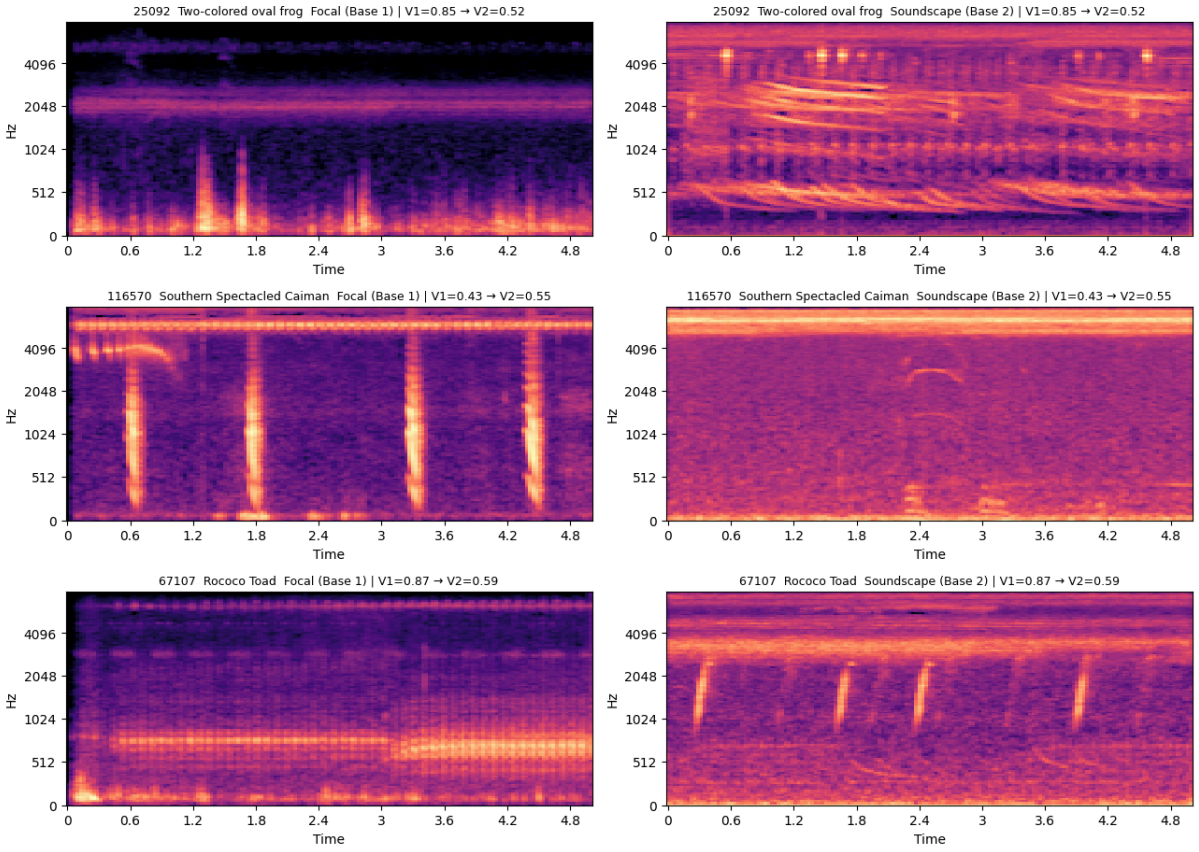
Du côté des oiseaux et mammifères, le gain vient plutôt de la meilleure généralisation : le Little Nightjar passe de 0,52 à 0,98, la Pauraque de 0,53 à 0,90, le Striated Heron de 0,57 à 0,94. Ce sont des espèces dont la signature acoustique n'était pas bien transférée focal → soundscape en v1, et qui bénéficient maintenant de l'ajout de 80 % de Base 2 dans le training.

Restent les huit classes en régression. Pour mieux comprendre, j'examine les trois cas les plus marqués via leur spectrogramme.

4.3 Trois cas illustratifs de difficultés persistantes

J'extrais des spectrogrammes mel pour trois classes représentatives des difficultés que la pipeline n'arrive pas encore à gérer. Chaque ligne compare un exemple focal (Base 1) et un exemple soundscape (Base 2).

Figure 6 Spectrogrammes focal vs soundscape pour les 3 classes pathologiques persistantes



25092 - Two-colored oval frog (Amphibia, v1 = 0,85 → v2 = 0,52). Le focal est dominé par un bruit large-bande continu autour de 2 kHz avec quelques pics sonores ponctuels en basse fréquence. Le soundscape, lui, présente un motif horizontal très différent : plusieurs

bandes horizontales régulières entre 2 et 5 kHz, sûrement d'un chœur de plusieurs individus. Quand v1 ne voyait que des soundscapes en évaluation, son modèle Base 1 trouvait par chance des corrélations exploitables. Avec la v2, l'entraînement intègre les soundscapes : le modèle réapprend, et découvre que la signature qu'il avait apprise sur le focal est en fait éloignée de celle des soundscapes annotés. C'est un cas pur de **domain gap** qui se révèle quand le training devient plus représentatif.

116570 - Southern Spectacled Caiman (Reptilia, v1 = 0,43 → v2 = 0,55). Le focal montre plusieurs appels courts et puissants en basse fréquence, visibles comme des barres verticales entre 0 et 1 kHz. Le soundscape correspondant est quasi-silencieux : le caïman vocalise rarement, et la plupart des segments labellisés positifs contiennent surtout du bruit ambiant avec un signal très ténu. Plus grave, la Base 1 ne contient qu'**un seul fichier focal** de caiman, donc apprendre une frontière de décision robuste sur un unique exemple est statistiquement impossible. La v2 améliore légèrement (+0,12) grâce à 26 positifs en Base 2, mais on plafonne à 0,55 : sans plus de données focal, on est durablement limité.

67107 - Rococo Toad (Amphibia, v1 = 0,87 → v2 = 0,59). Le focal montre un appel continu et régulier, concentré autour de 500-1000 Hz, signature très caractéristique. Le soundscape, lui, contient le crapaud mais noyé sous des transitoires d'oiseaux et autres amphibiens : la signature stationnaire qui définissait la classe en Base 1 est désormais dominée “énergétiquement” par d'autres sources. Les features statistiques moyennées sur 5 secondes ne savent pas isoler ce drone discret. Comme pour le frog 25092, la v2 révèle un problème que la v1 masquait : nos features ne savent pas séparer des sources sonores qui se superposent.

Ces trois cas illustrent trois pathologies différentes : domain gap qui se révèle quand le training devient plus réaliste (oval frog), insuffisance fondamentale de données (caiman), noyade énergétique en soundscape (rococo toad). Aucune n'est résolue par les améliorations v2 : ce sont des trous structurels que des features statistiques ne combleront pas seules.

4.4 Bilan

Mes pipelines gèrent bien les classes dont la signature reste cohérente entre focal et soundscape (la majorité des oiseaux et mammifères), et la v2 débloque mécaniquement les classes "Base 2 seule" que la v1 ne pouvait pas apprendre. Mais elles butent sur trois familles de cas : les classes à très peu d'exemples en Base 1, celles dont la signature dans les soundscapes est étouffée par d'autres sources, et plus généralement les classes pour lesquelles les statistiques moyennées sur 5 secondes ne capturent pas la spécificité. Ces limites pointent vers les directions concrètes que je discute en section 5 : représentations plus riches (embeddings sémantiques pré-entraînés), exploitation des métadonnées géographiques et temporelles, et techniques d'ensembling.

5. Perspectives : une v3 qu'on aurait aimé construire

L'analyse d'erreurs de la section 4 a fait apparaître trois familles de cas que la pipeline fait main ne traite pas bien : les classes au signal faible noyé dans un mélange, celles dont la signature focal diverge fortement de la signature soundscape, et celles dont les données

d'entraînement sont insuffisantes. Je propose ici quatre directions concrètes qui auraient pu constituer une v3, en discutant leur intérêt méthodologique et leur coût.

5.1 Embeddings sémantiques pré-entraînés

La piste la plus naturelle pour franchir le plafond des features statistiques est de remplacer le vecteur 307-dim par une représentation issue d'un réseau de neurones pré-entraîné sur de grandes quantités d'audio. Plusieurs modèles publics existent : BirdNET (Cornell Lab, entraîné notamment sur xeno-canto, sortie 1024-dim par segment 3 s), Perch (Google, sortie 1280-dim), et AVES (Apple, audio-visuel généraliste). Chacun produit un embedding qui encode une notion sémantique de l'espèce, là où mes 307 features ne capturent que des statistiques globales du spectre.

Pour les trois pathologies identifiées en section 4, l'apport théorique est important. Sur 25092 (Two-colored oval frog), un embedding sémantique reste cohérent malgré le passage focal → soundscape, parce qu'il a appris la notion abstraite de "chant de grenouille de l'espèce X", pas la forme du spectre moyen. Sur 67107 (Rococo Toad), un embedding sait isoler une signature même quand elle est masquée par d'autres sources, parce que le réseau a vu des millions de mélanges similaires en entraînement. Sur 116570 (caiman), l'apport reste limité parce que le problème est l'absence de données, pas la représentation.

J'ai tenté l'intégration de BirdNET via le package birdnet officiel. L'inférence sur CPU s'est révélée beaucoup trop lente pour la Base 1 en local : environ deux secondes par fichier focal en moyenne, soit plus de vingt heures pour l'ensemble selon mes estimations, et les tentatives d'accélération par batching ou parallélisation n'ont pas donné les gains attendus dans le temps imparti. Avec un accès GPU dédié, ou en se contentant d'une extraction par chunks sauvegardés au fur et à mesure, cette piste reste celle qui offrait le meilleur compromis effort/gain attendu

5.2 Exploitation des métadonnées non-audio

La Base 1 contient pour chaque enregistrement plusieurs champs que je n'ai jamais utilisés : latitude, longitude, month (date de l'enregistrement), recordist (auteur), rating (qualité 1-5 pour xeno-canto), length (durée), et secondary_labels. Seul ce dernier a été intégré dans la v2. Trois exploitations auraient été cohérentes avec les constats de la section 1 (97 % des enregistrements hors du Pantanal, dialectes régionaux possibles).

D'abord, un prior géographique : pour chaque espèce, je peux calculer la densité spatiale des enregistrements d'entraînement, puis pondérer la prédiction au moment de l'inférence selon la proximité du test (le Pantanal) à cette distribution. Une espèce dont 100 % des enregistrements proviennent d'Asie du Sud-Est verrait sa probabilité fortement abaissée dans le Pantanal. Cela aurait permis d'écarter mécaniquement des espèces théoriquement possibles mais géographiquement improbables, et ainsi d'améliorer la précision sur les classes rares.

Ensuite, un filtrage temporel : certaines espèces sont migratrices ou n'appellent qu'à certaines saisons. Le mois de l'enregistrement, couplé à la date du test (février-mars dans le Pantanal d'après les noms de fichiers), permet d'éliminer des candidats hors-saison.

Enfin, le rating xeno-canto aurait permis de tester l'hypothèse "qualité vs quantité" : entraîner sur les seuls enregistrements rating ≥ 3 plus tout iNaturalist, et comparer au baseline qui prend tout. Si le score progresse, la qualité prime sur la quantité, et on aurait élagué environ 30 % de la Base 1 sans perte. Si le score baisse, on confirme que même les enregistrements bruités apportent un signal exploitable. L'expérience est cheap (re-entraîner CatBoost prend 15 min) mais riche d'enseignement pour la suite.

5.3 Améliorations de la pipeline machine learning

Trois améliorations purement techniques auraient également mérité d'être tentées. La première est l'augmentation de données ciblée sur le domain gap focal → soundscape : ajout de bruit ambiant de soundscape sur les fichiers focaux pendant l'entraînement, mixage de plusieurs focaux pour simuler la co-occurrence multi-espèces des soundscapes. Ces techniques sont gratuites et ne demandent que de modifier la fonction de chargement. Elles auraient probablement réduit les régressions observées sur les amphibiens (25092, 67107) en exposant le modèle à des conditions plus réalistes dès l'entraînement.

La deuxième est un ensembling simple entre XGBoost et CatBoost. Ces deux modèles, malgré leurs scores différents (0,75 vs 0,80), font probablement des erreurs partiellement décorrélées. Une moyenne géométrique de leurs probabilités pourrait donner un gain sachant que le coût est nul si on a déjà les deux modèles entraînés.

La troisième est un tuning bayésien des hyperparamètres CatBoost via Optuna, en se concentrant sur les classes les plus difficiles plutôt qu'une recherche globale. Une dizaine d'essais ciblés sur la profondeur, la régularisation L2 et le bootstrap auraient pu améliorer les scores marginalement, mais cette piste est la moins prometteuse en termes de gain par heure investie.

5.4 Synthèse et priorisation

Si je devais classer ces pistes par retour sur investissement attendu, je placerais d'abord les embeddings pré-entraînés, qui apportent un gain clair sur la classe de problèmes la plus difficile (transfert focal → soundscape) mais demandent une infrastructure GPU dédiée. Vient ensuite l'augmentation de données, presque gratuite et directement ciblée sur le domain gap. Les métadonnées non-audio (prior géographique surtout) constituent un gain d'opportunité unique à ce projet, exploitant l'asymétrie entre données mondiales d'entraînement et test centré Pantanal. L'ensembling et le tuning apportent des gains marginaux mais sûrs, à garder pour la fin une fois les autres pistes épuisées.

6. Conclusion

Ce projet est parti d'un problème non trivial : classer 234 espèces de la faune du Pantanal à partir de signaux audio, en s'interdisant l'usage du deep learning. L'approche que j'ai choisie a consisté à parier sur la rigueur de l'analyse en amont plutôt que sur la puissance brute des modèles. Une analyse fine des trois sources de données (xeno-canto, iNaturalist, soundscapes du Pantanal) m'a permis d'identifier les vrais défis : un domain gap massif entre enregistrements focaux et soundscapes, une distribution géographique fortement

déséquilibrée, et une hétérogénéité acoustique selon les groupes biologiques. Chacun de ces constats a directement guidé une décision technique qui en a découlé.

La première version, fondée sur un vecteur fait main de 170 dimensions et un CatBoost en One-vs-Rest, atteint 0,728 sur le test caché Kaggle, score honorable pour une approche sans réseau de neurones entraîné. La seconde version, qui enrichit le vecteur à 307 dimensions, exploite le multi-label sur les secondary_labels, et combine Base 1 et Base 2 dans le training avec un hold-out propre par fichier soundscape, monte à 0,737 sur Kaggle. Le gain absolu peut paraître modeste, mais derrière il y a un changement plus important : la pipeline est passée de 47 classes entraînables à 229, et tous les groupes biologiques progressent Mammalia (+0,21), Aves (+0,18), Insecta (+0,16), Amphibia (+0,16), Reptilia (+0,12).

L'analyse d'erreurs a confirmé ce que l'analyse initiale laissait pressentir : la pipeline fait main gère bien les classes dont la signature reste cohérente entre focal et soundscape, mais elle bute sur trois familles de cas : domain gap profond, insuffisance de données focales, noyade énergétique des signaux discrets dans des mélanges complexes. Ces limites ne sont pas dues à un manque de tuning ou à un mauvais choix de classifieur : ce sont des trous structurels que des statistiques moyennées sur 5 secondes ne combleront pas, et qu'une vraie v3 devrait adresser via des embeddings sémantiques pré-entraînés, une exploitation des métadonnées géographiques et temporelles, et une augmentation de données ciblée sur le domain gap focal → soundscape.

Au-delà des résultats chiffrés, ce projet m'a fait réaliser à quel point la qualité du diagnostic conditionne celle des décisions techniques. Chaque choix : sous-échantillonnage à 16 kHz, cap de 20 segments par fichier, statistiques spectrales par groupes biologiques distincts, hold-out par fichier soundscape plutôt que par segment, calcul des AUC en distinguant les classes Confort des classes Base 2 seule trouve sa justification dans une observation préalable des données. Cette démarche donne une pipeline stable, interprétable et déjà performante sans entraînement de réseau profond. Les résultats obtenus montrent surtout que les descripteurs audio classiques restent pertinents, mais qu’ils atteignent leurs limites dès que le signal utile devient faible, mélangé ou trop différent entre l’entraînement et le test. C’est précisément sur ces points qu’une version suivante devrait se concentrer.

Références

Audio Signal Processing pour ML concepts généraux

[1] Velardo, V. (2020-2024). The Sound of AI - Audio Signal Processing for Machine Learning https://www.youtube.com/playlist?list=PL-wATfeyAMNqIee7cH3q1bh4QJFAaeNv0

[2] Librosa documentation https://librosa.org/doc/latest/feature.html

[3] Audio deep learning Made simple https://towardsdatascience.com/audio-deep-learning-made-simple-part-2-why-mel-spectrograms-perform-better-aad889a93505

[4] Kaggle. BirdCLEF 2026 https://www.kaggle.com/competitions/birdclef-2026